

Uzamsal Öznitelikler Kullanılarak Çekirdek Tabanlı Aşırı Öğrenme Makineleri ile PolSAR Görüntüsü Sınıflandırılması

Kernel Extreme Learning Machines for PolSAR Image Classification using Spatial Features

Ünsal Gökdağ^{*†}, Mustafa Üstüner[†], Gökhan Bilgin^{*}, Füsün Balık Şanlı[†]

^{*}Department of Computer Engineering, Yıldız Technical University, 34220 Istanbul

[†]Department of Geomatic Engineering, Yıldız Technical University, 34220 Istanbul

[‡]Seven Bridges Genomics, 34220 Istanbul

unsal.gokdag@ieee.org, {mustuner,gbilgin,fbalik}@yildiz.edu.tr

Özetçe —Bu çalışmada, dörtlü/tam polarizasyona sahip RADARSAT-2 Polarimetrik Sentetik Açıklıklı Radar (PolSAR) uydu görüntüsünün sınıflandırmasında polarimetrik ve uzamsal özelliklerin (feature) sınıflandırma doğruluğuna olan etkileri incelenmiştir. Hava koşullarından bağımsız olarak gece ve gündüz görüntü sağlayabilme avantajına sahip olan PolSAR sistemleri, hedef objelerin jeofiziksel özelliği (pürüzlülük, nemlilik) ve geometrik yapısı (dönüklük, şekil, boyut) hakkında bilgi sağlayabildiği için, uzaktan algılama alanında önemli bir veri kaynağıdır. PolSAR verileri, polarimetrik bilginin yanında uzamsal bilgiyi de içermektedir ve bu iki bilgi (polarimetrik ve uzamsal) PolSAR verisinden bilgi çıkarımında birbirini tamamlayıcı/bütünleyici niteliktedir. Çalışma kapsamında uzamsal özelliklerin çıkarımında morfolojik görüntü işleme teknikleri (açma ve kapama) kullanılmıştır. Görüntü sınıflandırma işlem adımında ise Çekirdek Tabanlı Aşırı Öğrenme Makineleri yöntemi seçilmiştir. Deneysel sonuçlarımız, polarimetrik ve uzamsal özelliklerin eklenmesi ile PolSAR verisinin sınıflandırma doğruluğunda %9.2'lik bir artış olduğunu göstermiştir. En yüksek sınıflandırma doğruluğu %82.61 olarak elde edilmiştir.

Anahtar Kelimeler—Polarimetrik SAR, çekirdek tabanlı aşırı öğrenme makineleri, sentetik açıklıklı radar (SAR), sınıflandırma.

Abstract—In this study, the impacts of polarimetric and spatial features on the classification accuracy of full polarimetric SAR (PolSAR) RADARSAT-2 data was investigated. Since PolSAR systems have the advantage of providing day-and-night and weather-independent images could provide the geo/bio-physical and structural information about the target objects hence are an important data source for remote sensing. PolSAR data includes geophysical (roughness and moisture), geometric (rotation, shape, size) and polarimetric as well as spatial information, as these information can be considered complementary. In this study, morphological features (opening and closing) were implemented to extract spatial features. Kernel based extreme learning machines (kELM) was used for data classification. Our results demonstrated that the classification accuracy is increased by 9.2% via inclusion of polarimetric and spatial features with highest classification accuracy was obtained as 82.61%.

Keywords—Polarimetrik SAR, kernel extreme learning ma-

chines, synthetic aperture radar (SAR), classification.

I. Giriş

Polarimetrik SAR (PolSAR; Sentetik Açıklıklı Radar) görüntüleri, özellikle son 10 yılda radar uydularında yaşanan gelişmeler ile birlikte uzaktan algılama alanındaki araştırmacıların büyük ilgisini çekmiştir. Hava koşullarından bağımsız olarak gece ve gündüz, görüntü sağlayabilme avantajına sahip olan PolSAR sistemleri, hedef objelerin jeofiziksel özelliği (pürüzlülük, nemlilik) ve geometrik yapısı (dönüklük, şekil, boyut) hakkında bilgi sağlayabildiği için, uzaktan algılama alanında önemli bir veri kaynağıdır ve son yıllardaki kullanımı da giderek artmaktadır. PolSAR verileri, hedef objeler hakkında optik uzaktan algılama verileri ile elde edilemeyen ve optik uzaktan algılama verilerine tamamlayıcı bilgiler sağladığı için özellikle tarım, ormancılık, jeoloji ve buzul ile ilgili çalışmalarda tercih edilmektedir. SAR görüntülerinin alım geometrisi, görüntü karakteristik özellikleri ve karmaşık yapılarından kaynaklı olarak görüntü işleme ve yorumlama adımları optik uzaktan algılama görüntülerine nazaran daha zahmetlidir ve bilgi çıkarımında kullanılan yöntemler, hem matematiksel hem de fiziksel temellere (geri saçılım mekanizmasına dayalı) dayandığı için daha karmaşıktır [1], [2], [3].

Uzaktan algılamada bilgi çıkarımı amacıyla kullanılan yöntemlerin başında eğitici sınıflandırma yöntemleri gelmektedir ve bu yöntemler, sınıflandırma işleminde gerçek sayıları kullanmaktadır. SAR görüntüleri ise karmaşık değerlere sahip verilerdir ve genellikle saçılım matrisi $[S]$ ya da kovaryans $[C]$, eşvirelilik $[T]$ matrisleri formunda tutulurlar. Örnekte tanımlanan eğitici sınıflandırma işleminde, bu karmaşık yapıdaki verilerden gerçek sayı uzayına dönüşümler yapılır ve sınıflandırma işlemine girdi veriler (polarimetrik parametreler, SPAN) hazırlanır [2], [4]. Eğitici sınıflandırma işleminde, yüksek sınıflandırma başarımı, sınıflandırma işleminde kullanılacak modelin gürbüzlülük düzeyinin yanı sıra, modelin öğrenme sürecinde kullanılacak olan girdi verilere ve eğitim

verisine bağlıdır [5]. Polarimetrik SAR görüntüleri bünyesinde hem polarimetrik hem de uzamsal bilgiyi içermektedir ve PolSAR verilerinin bilgi çıkarımı amacıyla kullanımında, polarimetrik ya da uzamsal bileşenlerin tek başına kullanımı ile PolSAR verisi tam olarak temsil edilememektedir. Bu iki bileşen birbirini tamamlayan bilgiler sağlamaktadır [6], [7]. Karmaşık yapıdaki polarimetrik SAR verilerinden hedef objeler hakkında polarimetrik bilgilerin çıkarılması amacıyla polarimetrik ayrıştırma yöntemleri kullanılmaktadır. Polarimetrik ayrıştırma teknikleri tutarlı(coherent) ve tutarlı olmayan (incoherent) ayrıştırma teknikleri olmak üzere ikiye ayrılmaktadır. Genellikle tutarlı ayrıştırma teknikleri yapay hedefler/sınıflar (insan yapımı yapılar: binalar, kent alanları, havaalanları vb.) için kullanılırken, tutarlı olmayan ayrıştırma teknikleri ise doğal hedeflerin/sınıfların (ormanlık alanlar, tarım alanları, sulak alanlar vb.) tespit edilmesinde kullanılmaktadır [3], [8], [9]. Uzaktan algılamada uzamsal özelliklerin çıkarımı amacıyla görüntü bölütleme, dokusal analizler (oluşum ve eş-oluşum tabanlı doku filtreleri) ve morfolojik görüntü işleme teknikleri vb. yöntemler kullanılmaktadır. Özellikle morfolojik görüntü işleme teknikleri ile çıkarılan uzamsal özelliklerin, optik uzaktan algılama verilerinde (multispektral, hiperspektral) sınıflandırma başarımlarını artırdığı gözlenmiştir [7], [10].

Eğitici sınıflandırma işleminde, parametrik yapıda olmayan makine öğrenme algoritmaları uzaktan algılama verilerinin sınıflandırılması işleminde uzun yıllardır kullanılmaktadır. Bu yöntemlerin başında Yapay Sinir Ağları, Destek Vektör Makineleri ve rastgele orman algoritması yöntemleri gelmektedir. 1990'lı yılların başında popüler hale gelen yapay sinir ağları, hesaplama karmaşıklığı ve parametre optimizasyonundaki sorunlar nedeniyle genellikle diğer parametrik yapıda olmayan yöntemlere kıyasla düşük sınıflama başarımları vermesi nedeniyle çok tercih edilmemektedir [11], [12]. Yapay zekâ ve makine öğrenmesi alanındaki son gelişmeler ile birlikte, örüntü tanıma ve uzaktan algılanmış görüntülerin sınıflandırılması işlemlerinde ileri düzey algoritmalar kullanılmaya başlanmıştır. Özellikle son yıllarda örüntü tanıma ve uzaktan algılama alanında aktif öğrenme, derin öğrenme, yarı-güdümlü öğrenme, aşırı öğrenme makinesi ve çekirdek tabanlı aşırı öğrenme makinesi yöntemleri araştırmacıların ilgisini çekmekte ve etkili bir şekilde kullanılmaktadır. Multispektral ve hiperspektral verilerin analiz edilmesinde kullanılan bu ileri düzey algoritmaların, SAR (PolSAR) verilerinin analizinde kullanımı diğerlerine nazaran daha az sayıdadır [7].

Bu çalışmada, dörtlü/ polarizasyona (D: Düşey (vertical); Y: Yatay (horizontal); DD, DY, YD, YY) sahip RADARSAT-2 SAR uydu görüntüsünün sınıflandırılmasında, PolSAR verisinden üretilen SPAN (toplam saçılım gücü) parametresi ve SPAN parametresinden morfolojik görüntü işleme teknikleri ile çıkarılan uzamsal özelliklerin sınıflandırma doğruluğuna olan etkileri incelenmiştir. Çalışma kapsamında, eşvrelilik $[T]$ matrisi formatında tutulan PolSAR görüntüsü, SPAN parametresi ve SPAN parametresinden morfolojik görüntü işleme teknikleri (açma ve kapama) ile çıkarılan uzamsal özelliklerin kullanılmıştır. Görüntülerin sınıflandırma işleminde ise Çekirdek Tabanlı AÖM sınıflandırma yöntemi seçilmiştir. Çalışma kapsamında, polarimetrik ve uzamsal bileşenleri de içeren veri küpünün, orijinal verinin sınıflandırma doğruluğu üzerinde nasıl bir etkisi olduğu izlenmiş ve elde edilen sonuçlar karşılaştırılarak analiz edilmiştir.

II. ÇALIŞMA ALANI VE KULLANILAN VERİLER

RADARSAT-2 uydusu dört farklı polarizasyonda yüksek çözünürlüklü görüntü elde etmemizi sağlayan 2007 yılında Kanada tarafından uzaya gönderilmiş bir yer gözlem uydusudur. Çalışma kapsamında 2 Nisan 2008 tarihli dörtlü polarizasyona sahip RADARSAT-2 SAR uydu görüntüsü kullanılmıştır ve görüntü "Fine Quad-Pol" görüntü alım modunda elde edilmiştir. Görüntünün uzamsal çözünürlüğü 8 metredir ve 1300×1200 piksellik bir alanı kaplamaktadır. RADARSAT-2 SAR uydu görüntüsü eşvrelilik $[T]$ matrisi formatında ve yer gerçekliği verileri Dr. Alim Samat'dan (Çin Bilimler Akademisi) temin edilmiştir [7]. Çalışmalarında $[T]$ matrisinin üretilmesinden önce, veriye benek filtreleme ve çoklu bakış işlemi uygulanmıştır. Elde ettiğimiz bu veriye tarafımızca herhangi bir benek filtreleme yada çok bakışlılık işlemi uygulanmamıştır.

Çalışma alanı Hollanda Flevoland ili sınırları içerisinde kalmaktadır (Şekil 1).



Şekil 1: Çalışma Alanı (2 Nisan 2008-Flevoland,Hollanda)

Çalışma alanında dört adet arazi kullanımı sınıfı (su, ağaçlık alan, tarım arazileri ve kent) bulunmaktadır. Çalışmada kullanılan eğitim/test veri setine ilişkin bilgiler Tablo I'de görülmektedir.

TABLO I: Eğitim ve Test Veri Seti

Sınıf No	Sınıflar	Eğitim (Piksel)	Test (Piksel)
1	Su	1259	113645
2	Ağaçlık Alan	1582	162268
3	Tarım Arazileri	1481	198383
4	Kent	1552	193994

III. SAR VERİLERİNİN ÖNİŞLENMESİ VE SINIFLANDIRILMASI

Çalışma kapsamında eşvrelilik $[T]$ matrisi formatında elde PolSAR görüntüsünden, SPAN görüntüsü üretilmiştir. Bu işlemin ardından ise, SPAN görüntüsünden morfolojik görüntü işleme teknikleri ile uzamsal özellikler çıkarılmıştır.

A. Polarimetrik ve Uzamsal Özelliklerin Oluşturulması

Tek bakışlı karmaşık görüntü formatındaki (Single Look Complex - SLC) formatındaki PolSAR görüntülerindeki bilgi,

her bir piksel için $[S]$ saçılım matrisi formatında tutulur.

$$[S] = \begin{bmatrix} S_{yy} & S_{yd} \\ S_{dy} & S_{dd} \end{bmatrix}$$

Monostatik radar durumlarında, $[S]$ saçılım matrisi simetrik hale gelmektedir ve $S_{dy}=S_{yd}$ olmaktadır. Bu durumda saçılım matrisi $k_P = [S_{yy} + S_{dd} \quad S_{yy} - S_{dd} \quad 2S_{yd}]^T / \sqrt{2}$ olarak yazılabilir. Burada T vektörün transpozisini ifade etmektedir. Eşvirelilik $[T]$ matrisi ise $[T] = \langle k_P k_P^H \rangle =$ formülü ile elde edilebilir. Bu formülde $\langle \cdot \rangle$ çok bakışlılık işlemini, k_P^H ise k_P 'nin konjüge transpozisini temsil etmektedir [1], [6], [3].

$$[T] = \begin{bmatrix} T_{11} & T_{12} & T_{13} \\ T_{21} & T_{22} & T_{23} \\ T_{31} & T_{32} & T_{33} \end{bmatrix}$$

Çalışma kapsamında $[T]$ matrisin izi kullanılarak **SPAN** görüntüsü üretilmiştir [1], [6], [3].

$$[SPAN] = |S_{yy}|^2 + 2 \times |S_{dy}|^2 + |S_{dd}|^2$$

Uzaktan algılanmış görüntülerden hedef objelere/sınıflara ilişkin ek uzamsal bilgilerin çıkarılmasında yaygın olarak dokusal analizler (oluşum ve eş-oluşum tabanlı doku filtreleri) ve morfolojik görüntü işleme teknikleri (aşındırma, yayma, açma ve kapama) kullanılmaktadır. Aşındırma ve yayma morfolojik görüntü işlemenin temel işlem adımlarındandır. Aşındırma işleminde hedef bölgedeki sınırların yada nesnelerin inceltilmesi, yaymada ise kalınlaştırması söz konusudur. Açma işleminde görüntüye önce aşındırma işlemi ve daha yaymada işlemi uygulanır. Kapama işleminde ise önce yayma işlemi ve daha sonra aşındırmada işlemi uygulanır [7], [13]. Uzamsal özellikler SPAN görüntüsünden üretilmiştir.

Elde edilmiş olan F1 ve F2 verilerinin sınıflandırılması için Çekirdek Tabanlı AÖM kullanılmıştır.

TABLO II: Çalışma Kapsamında Kullanılan Veri Kümeleri

Veri Seti No	Açıklama	Özellik Sayısı	Toplam Özellik Sayısı
F1	$T_{11}, T_{12}, T_{13}, T_{22}, T_{23}, T_{33}$	6	6
F2	$T_{11}, T_{12}, T_{13}, T_{22}, T_{23}, T_{33}$	6	21
	Polarimetrik SPAN	1	
	Morfolojik Operatörler	$7 \times 2 = 14$	

B. Çekirdek Tabanlı Aşırı Öğrenme Makineleri

Aşırı Öğrenme Makineleri (AÖM) mimarisinin çıkış aşamasında biyolojik yapıların evrensel öğrenme özellikleri ve beyin içerisindeki nöronların çevresinden bağımsız şekilde rastgele ağırlıklara sahip olması üzerinden ilham alınmıştır [14], [15], [16], [17] ve elde edilen yöntem AÖM adı verilmiştir. AÖM mimarisi klasik yapay sinir ağlarından farklı olarak geri-iletim mekanizmasına sahip değildir ve bu sebeple doğru optimizasyon yöntemleri kullanarak geri-iletim tabanlı yapay sinir ağlarından çok daha hızlı eğitilebilir [18]. AÖM mimarisine tek katmanlı yapay sinir ağı olarak başlanmış ve genel çıkış fonksiyonu şu şekilde tanımlanmıştır:

$$f_L(x) = \sum_{i=1}^L \beta_i h_i(x) = h(x) \beta$$

Buradaki $\beta = [\beta_1, \dots, \beta_L]^T$ gizli katman ile çıkış nöronları arasındaki ağırlık matrisini ifade eder. $h(x) = [h_1(x), \dots, h_L(x)]$ ise gizli katmandaki nöronların sonuçlarının vektör şeklinde gösterilmesidir. Gizli katmandaki nöronların değerlerinin ara bir fonksiyondan geçirilmesi çekirdek tabanlı aşırı öğrenme makinelerinin çekirdek yapısını oluşturur. Bu aşamada $h(x)$ matrisi:

$$h_i(x) = G(a_i, b_i, x), a_i \in \mathbb{R}^d, b_i \in \mathbb{R}$$

üzerinden tanımlanır. Bu aşamada G fonksiyonu AÖM'nin evrensel yakınsama özelliklerini koruyacak şekilde yapılandırılabilir. Bu çalışmada kullanılan çekirdek fonksiyonları:

1) Sigmoid fonksiyonu:

$$G(a, b, x) = \frac{1}{1 + \exp(-(a \cdot x + b))}$$

2) Rektifiye lineer çıkış:

$$G(a, b, x) = \begin{cases} 1, & a \cdot x - b \geq 0 \\ 0, & \text{diğer} \end{cases}$$

3) Polinom çekirdek fonksiyonu:

$$G(a, b, x) = (x + a)^b$$

4) İkinci derece radyal tabanlı fonksiyon:

$$G(a, b, x) = \sqrt{\|x - a\|^2 + b^2}$$

Bu çekirdek fonksiyonları dışında Mercer koşulu sağlayan tüm fonksiyonlar çekirdek olarak entegre edilebilir [19].

$h(x)$ fonksiyonu d boyutlu giriş uzayından L boyutlu gizli uzaya dönüşüm yapılmasını sağlar. Buradaki $\beta = [\beta_1, \dots, \beta_L]^T$ gizli katman ile çıkış nöronları arasındaki ağırlık matrisini ifade eder. Gizli katman sonucu şu şekilde gösterilir:

$$H\beta = T$$

ve bu denklemin çözümü

$$\beta = H^\dagger T$$

olarak hesaplanır. Buradaki † işlemi Moore-Penrose genel matris tersi yöntemi olup uygulandığı zaman ortaya bu denklem çıkar:

$$B = H^\dagger \left(\frac{I}{C} + HH^\top \right)^{-1} T$$

Bu denklem içerisinde kullanılan $\frac{I}{C}$ denklemin durağanlığını yükseltmek için eklenen birim matrisinin C değerine bölünmüş halidir.

IV. SONUÇLAR VE DEĞERLENDİRME

Bu çalışmada Çekirdek Tabanlı AÖM RADARSAT-2 PolSAR uydu görüntüsü üzerindeki sınıflandırma başarımları ve aynı zamanda polarimetrik ve uzamsal özelliklerin sınıflandırma doğruluğuna olan etkileri incelenmiştir. Çalışma kapsamında, PolSAR verisinden polarimetrik özellik olarak SPAN görüntüsü ve SPAN görüntüsünden morfolojik görüntü işleme teknikleri ile çıkarılan uzamsal özellikler üretilmiştir. Çalışma

içerisinde kullanılan Çekirdek Tabanlı AÖM yapısının bir-
den fazla hiperparametresi bulunmakta ve bu parame-
treler sınıflandırma başarımını önemli ölçüde etkilemekte-
dir. Yapılan çalışmada bu hiperparametreler ızgara arama
yöntemi ile taranmış ve en iyi sonuçlar kaydedilmiştir.
Taranan hiperparametreler şunlardır: Regularizasyon Parame-
tresi $C = \{10^{-6}, 10^{-4}, 10^{-2}, 10^0, 10^2, 10^4, 10^6\}$, çekirdek
fonksiyonu: $G = \{sigmoid, polinom, ReLU, RTF\}$, $a =$
 $\{1, 2, 3, 4, 5, 6, 7, 8, 9, 10\}$, $b = \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10\}$.
Mevcut çalışma Pentium Core i7 işlemci, 128GB ram ve Tesla
K40 ekran kartı üzerinde çalışılmıştır. Çekirdek Tabanlı AÖM
yapısında kullanılan hiperparametreler $F1$ veri kümesi için
 $C = 10^6$, çekirdek: RTF $a = 1$, $b = 1$, $F2$ veri kümesi için
 $C = 10^6$, çekirdek: RTF $a = 8$, $b = 8$.

Deneyisel sonuçlarımız, polarimetrik ve uzamsal özellik-
lerin eklenmesi ile PolSAR verisinin sınıflandırma doğru-
luğunda %9.2'lik bir artış olduğunu göstermiştir. En yüksek
sınıflandırma doğruluğu %82.61 olarak elde edilmiştir.

Sınıflandırma başarımının hiperparametreye göre has-
sasiyeti kullanılan hiperparametre değerlerine göre değişik-
lik göstermektedir. Yapılan çalışmada en yüksek başarımlar
veren hiperparametre değerlerinde çekirdek fonksiyonları
sabit bırakıldığı zaman çekirdek parametrelerinin değiştir-
ilmesi sınıflandırma başarımını %1'den daha az etkilemek-
tedir. Sınıflandırma başarımındaki değişim miktarının AÖM
ile gerçekleştirilmesi ilgili sınıflandırma yönteminin bütün
veri kümesini aynı anda eğitim için kullanmasından veya bu
yöntemin YSA aksine L2 mesafe yöntemi kullanmasından
kaynaklanıp kaynaklanmadığı araştırılmalıdır.

TABLO III: Sınıflama Başarımları: $F1$ ve $F2$ için

Veri Seti No	Toplam Doğruluk (%) (Başarımlar Oranı)	Kappa Değerleri
$F1$	73.41	0.6430
$F2$	82.61	0.7661

Ayrıca $F1$ ve $F2$ için sonuçlarımızda elde edilmiş olan
sınıflandırma başarımları referans çalışma [7] ile Tablo IV'de
karşılaştırılmıştır..

TABLO IV: $F1$ ve $F2$ Veri Kümeleri için Referans Çalışma ile
Önerilen Yöntem Sınıflama Başarımlarının Karşılaştırılması

Veri Seti No	Toplam Doğruluk (%) (Başarımlar Oranı)				
	Referans Çalışma[7]				Önerilen Yöntem
	Wishart	DVM	Rastgele Orman	Rotasyon Tab. AÖM	Çekirdek Tab. AÖM
$F1$	74.33	74.37	72.93	73.92	73.41
$F2$	-	73.98	75.24	75.68	82.61

Bu çalışmamızın devamı olarak, Çekirdek Tabanlı AÖM
yönteminin sınıf sayısı daha fazla olan tematik çalışma alan-
larında (tarım ve ormanlık alanlar, sulak alanlar) farklı karak-
terdeki polarimetrik ve uzamsal özellikler ile test edilmesi
planlanmaktadır. Ayrıca özellik seçimi yöntemleri gelecek
çalışmalarımızda kullanılacaktır. Benzer çalışmanın optik uza-
ktan algılama verileri (Sentinel-2, Landsat-8 vb.) ile de yapıl-
ması planlanmaktadır

BİLGİLENDİRME

Radarsat-2 SAR uydü görüntüsünün ücretsiz temini için
MDA Geospatial Services Inc. teşekkür ederiz.

KAYNAKÇA

- [1] J. Lee and E. Pottier, "Introduction to the polarimetric target de-
composition concept," *Polarimetric Radar Imaging: From Basics to
Applications*; CRC Press: Boca Raton, FL, USA, pp. 1–422, 2009.
- [2] R. Hänsch and O. Hellwich, "Skipping the real world: Classification
of polsar images without explicit feature extraction," *ISPRS Journal of
Photogrammetry and Remote Sensing*, 2017.
- [3] A. Moreira, P. Prats-Iraola, M. Younis, G. Krieger, I. Hajnsek, and
K. P. Papathanassiou, "A tutorial on synthetic aperture radar," *IEEE
Geoscience and Remote Sensing Magazine*, vol. 1, no. 1, pp. 6–43,
2013.
- [4] G. Moser and S. B. Serpico, "Kernel-based classification in complex-
valued feature spaces for polarimetric sar data," in *IEEE International
Geoscience and Remote Sensing Symposium, IGARSS'14*, 2014, pp.
1257–1260.
- [5] T. Kavzoglu, "Increasing the accuracy of neural network classification
using refined training data," *Environmental Modelling & Software*,
vol. 24, no. 7, pp. 850–858, 2009.
- [6] X. Wang, Z. Cao, Y. Ding, and J. Feng, "Composite kernel method for
polsar image classification based on polarimetric-spatial information,"
Applied Sciences, vol. 7, no. 6, p. 612, 2017.
- [7] P. Du, A. Samat, B. Waske, S. Liu, and Z. Li, "Random forest
and rotation forest for fully polarized sar image classification using
polarimetric and spatial features," *ISPRS Journal of Photogrammetry
and Remote Sensing*, vol. 105, pp. 38–53, 2015.
- [8] H. McNairn, J. Shang, X. Jiao, and C. Champagne, "The contribution
of alos palsar multipolarization and polarimetric data to crop classifica-
tion," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 47,
no. 12, pp. 3981–3992, 2009.
- [9] A. Larrañaga and J. Álvarez-Mozos, "On the added value of quad-
pol data in a multi-temporal crop classification framework based on
radarsat-2 imagery," *Remote Sensing*, vol. 8, no. 4, p. 335, 2016.
- [10] M. Fauvel, J. A. Benediktsson, J. Chanussot, and J. R. Sveinsson,
"Spectral and spatial classification of hyperspectral data using SVMs
and morphological profiles," *IEEE Transactions on Geoscience and
Remote Sensing*, vol. 46, no. 11, pp. 3804–3814, 2008.
- [11] B. Waske and J. A. Benediktsson, "Fusion of support vector machines
for classification of multisensor data," *IEEE Transactions on Geoscience
and Remote Sensing*, vol. 45, no. 12, pp. 3858–3866, 2007.
- [12] M. Pal, A. E. Maxwell, and T. A. Warner, "Kernel-based extreme
learning machine for remote-sensing image classification," *Remote
Sensing Letters*, vol. 4, no. 9, pp. 853–862, 2013.
- [13] J. A. Benediktsson, M. Pesaresi, and K. Amason, "Classification and
feature extraction for remote sensing images from urban areas based
on morphological transformations," *IEEE Transactions on Geoscience
and Remote Sensing*, vol. 41, no. 9, pp. 1940–1949, 2003.
- [14] G.-B. Huang, Q.-Y. Zhu, and C.-K. Siew, "Extreme learning machine:
a new learning scheme of feedforward neural networks," in *IEEE
International Joint Conference on Neural Networks*, vol. 2, 2004, pp.
985–990.
- [15] G.-B. Huang, Q.-Y. Zhu, and Siew, "Extreme learning machine: theory
and applications," *Neurocomputing*, vol. 70, no. 1–3, pp. 489–501, 2006.
- [16] G.-B. Huang, L. Chen, C. K. Siew *et al.*, "Universal approximation
using incremental constructive feedforward neural networks with random hid-
den nodes," *IEEE Transactions on Neural Networks*, vol. 17, no. 4, pp.
879–892, 2006.
- [17] G.-B. Huang and L. Chen, "Convex incremental extreme learning
machine," *Neurocomputing*, vol. 70, no. 16–18, pp. 3056–3062, 2007.
- [18] P. Ghamisi, J. Plaza, Y. Chen, J. Li, and A. J. Plaza, "Advanced spectral
classifiers for hyperspectral images: A review," *IEEE Geoscience and
Remote Sensing Magazine*, vol. 5, no. 1, pp. 8–32, March 2017.
- [19] G.-B. Huang, "An insight into extreme learning machines: Random
neurons, random features and kernels," *Cognitive Computation*, vol. 6,
no. 3, pp. 376–390, Sep 2014.