

Sentinel-1A SAR Görüntüsü ile Arazi Örtüsü ve Kullanımı Sınıflandırması: İstanbul Örneği

Land Use and Cover Classification of Sentinel-1A SAR Imagery: A Case Study of Istanbul

Mustafa Üstüner ve Fusun Balık Şanlı
Harita Mühendisliği Bölümü
Yıldız Teknik Üniversitesi
İstanbul, Türkiye
mustuner@yildiz.edu.tr, fbalik@yildiz.edu.tr

Gökhan Bilgin
Bilgisayar Mühendisliği Bölümü
Yıldız Teknik Üniversitesi
İstanbul, Türkiye
gbilgin@yildiz.edu.tr

Saygın Abdikan
Geomatik Mühendisliği Bölümü
Bülent Ecevit Üniversitesi
İstanbul, Türkiye
sabdikan@beun.edu.tr

Özetçe—Bu çalışmada, Sentinel-1A SAR (Sentetik Açıklıklı Radar) görüntüsünün arazi örtüsü ve kullanımı sınıflandırmasında kullanılabilirliği ve sınıflandırma algoritmaları üzerindeki etkileri araştırılmıştır. İkili/çift polarizasyona (DD, DY; D:Düşey, Y:Yatay) sahip Sentinel-1A görüntüsü Avrupa Uzay Ajansı'ndan ücretsiz olarak elde edilmiştir. Çalışma alanı olarak İstanbul seçilmiştir. Elde edilen SAR görüntüsünün, yörünge düzeltmesi, veri kalibrasyonu, multilooking işlemi, benek (speckle) filtrelemesi ve arazi düzeltmesi (terrain correction) işlemlerinin ardından sınıflandırma işlemine geçilmiştir. Çalışma kapsamında üç farklı sınıflandırma tekniği (Destek Vektör Makineleri (DVM), Rastgele Orman(RO) ve K-En Yakın Komşuluk(K-EYK)) kullanılmış ve orijinal iki banttan oluşturulmuş diğer bantların (DD-DY, DD+DY vb.) etkisi incelenmiştir. Çalışmada en yüksek sınıflandırma doğruluğu (%81.90) orijinal iki bantın DVM yöntemi ile sınıflandırılması sonucu elde edilmiştir. Diğer bantların sınıflandırma doğruluğuna olan etkisinin seçilen algoritmaya göre farklılık gösterdiği gözlenmiştir.

Anahtar Kelimeler — *Sentinel-1A; Sentetik Açıklıklı Radar (SAR); destek vektör makineleri; rastgele orman; sınıflandırma.*

Abstract—In this study, Sentinel-1A SAR imagery for land use/cover classification and its impacts on classification algorithms were addressed. Sentinel-1A imagery has dual polarization (VV and VH) and freely available from ESA. Istanbul was selected as the study region. After the pre-processing steps including the applying the precise orbit file, calibration, multilooking, speckle filtering and terrain correction, the imagery was classified as the following step. Three classification algorithms (SVM, RF and K-NN) were implemented and the impacts of additional bands (VV-VH, VV+VH etc.) were investigated. Results demonstrated that highest classification accuracy of this study was obtained by SVM classification with the original bands (VV and VH) of Sentinel-1A imagery. Moreover, it was concluded that additional bands had different impacts on each classifier within accuracy.

Keywords — *Sentinel 1-A; Synthetic aperture radar; support vector machines; random forest; classification.*

I. GİRİŞ

Uzaktan algılama, arazi örtüsü/kullanımı sınıflandırmasından iklim değişikliğine, afet yönetiminden buzulların izlenmesine kadar geniş bir kullanım alanına sahiptir. Artan nüfus artışı ve azalan doğal kaynaklar ile birlikte başta tarım alanları olmak üzere doğal kaynakların sürdürülebilir yönetimi giderek önem kazanmaktadır. Uzaktan algılama yeryüzüne ait, farklı zamansal ve mekânsal çözünürlükte ucuz ve hızlı veri sağlayabilmesi nedeniyle doğal kaynakların sürdürülebilir yönetimi ve etkin kullanımında önemli avantajlar sağlamaktadır [1].

Hava koşullarından bağımsız olarak gece ve gündüz, yüksek çözünürlüklü görüntü sağlayabilme avantajı nedeniyle aktif algılama sistemleri uzaktan algılamada son yıllarda sıklıkla kullanılmaktadır ve pasif sistemlerin görüntü alımındaki kısıtlamaların önüne geçmektedir. SAR (Sentetik açıklıklı radar) görüntüleri hedef objelerin fiziksel özellikleri hakkında bilgiler sunmaktadır ve bu nedenle arazi örtüsü/kullanımı, ormancılık, jeoloji ve buzul ile ilgili çalışmalarda tercih edilmektedir. SAR verisi, hedef objenin elektriksel özelliği (pürüzlülük, nemlilik) ve geometrik yapısı (dönüklük, şekil, boyut) hakkında bilgi sağladığı için özellikle arazi örtüsü ile ilgili çalışmalarda optik görüntülere göre çok büyük avantajlar sağlamaktadır [2,3]. Son yıllarda sayıları giderek artan farklı polarizasyona (tek, çift ve dördü/tam polarizasyon) sahip SAR görüntüleri, özellikle optik görüntülerin temin edilemediği zamanlarda (TERRASAR-X, RADARSAT-2, ALOS-2, SENTINEL-1 vb.) arazi örtüsü/kullanımı, tarım, orman ve bitki örtüsü ile ilgili çalışmalarda etkin bir şekilde kullanılmaya başlamıştır. [4]'te arazi örtüsünün sınıflandırılması amacıyla çok zamanlı SAR

görüntüleri (ENVISAT ve ERS-2) kullanılmıştır. Çalışmada %84'lük sınıflandırma doğruluğu elde etmişlerdir. [2] nolu çalışmada çok zamanlı RADARSAT-2 verileri yardımıyla kentsel arazi örtüsünü tespit etmek amacıyla nesne tabanlı ve kural tabanlı sınıflandırma yöntemlerini kullanılmıştır. Çalışmalarında % 81'lik doğrulukla kentsel arazi örtüsü tespit edilmiştir. [5]'te CORINE arazi örtüsü sınıflandırması amacıyla Sentinel-1A verisini kullanılmıştır. Çalışmalarının sonunda Sentinel-1A SAR görüntüsünün CORINE arazi örtüsü sınıflarından birbirinden ayrılabilmesinde etkili bir biçimde kullanılabileceği ve özellikle bulutlu alanlarda kullanışlı olacağı sonucuna varmışlardır. [6]'da aktif aşırı öğrenme makinelerinin (active extreme learning machines) dörtlü polarizasyona sahip SAR görüntülerin sınıflandırılmasındaki kullanımını araştırılmıştır. Çok polarizasyonlu/frekanslı ve çok zamanlı SAR görüntülerinin (TERRASAR-X, RADARSAT-2, ENVISAT-ASAR) yüksek doğrulukta ürün deseninin tespit edilmesine çalışılmıştır [7]. Çalışmada en çok benzerlik ve rastgele orman algoritmaları kullanılmıştır. Son yıllarda ileri düzey sınıflandırma algoritmaları (derin öğrenme, topluluk öğrenme algoritmaları, yarı güdümlü öğrenme vb.) uzaktan algılamada yaygın olarak kullanılmaktadır. Uydu görüntülerinin sınıflandırılması işleminde algoritmanın öğrenme süreci karmaşık olup birçok bileşene (eğitim veri kümesinin karakteristik özelliği, verinin çözünürlüğü, karmaşıklığı ve eğitim piksellerinin sınıfları ne doğrulukta temsil ettiği vb.) bağlıdır [8,9]. Eğitim veri kümesindeki piksellerin istatistiksel dağılımını dikkate almaması avantajı nedeniyle bu çalışmada parametrik olmayan sınıflandırma yöntemleri seçilmiştir. Destek Vektör Makineleri, parametrik olmayan yapısı ve az sayıda eğitim verisi ile yüksek boyutlu verilen sınıflandırılmasında tatminkâr sonuçlar vermesi nedeniyle optik ve radar görüntülerinin sınıflandırılmasında sıklıkla kullanılmaktadır [10].

Bu çalışmada çift polarizasyona sahip Sentinel-1A SAR uydu görüntüsü kullanılmıştır. Çalışma kapsamında, orijinal bantlara (DD, DY) ek olarak matematiksel işlemler sonunda üç adet ek bant (DD-DY, DD+DY, DD-DY/DD+DY) oluşturularak beş bantlı bir veri kümesi oluşturulmuştur. Bu ek bantların sınıflandırma doğruluğuna olan etkisinin üç farklı sınıflandırma yöntemi (DVM, RO ve K-EYK) ile araştırılması amaçlanmıştır. SAR görüntüsünün sınıflandırması işleminde, parametrik olmayan yapıları nedeniyle DVM, RO ve K-EYK yöntemleri kullanılmıştır.

II. ÇALIŞMA ALANI VE VERİ KÜMESİ

Son yıllarda yaşanan hızlı nüfus artışı ve yüksek kentleşme oranı ile birlikte İstanbul'da arazi örtüsü/kullanımı yapısı hızlı bir şekilde değişmektedir. Arazi örtüsündeki bu değişimin doğru tespit edilmesi de şehrin sağlıklı planlanması ve etkili yönetimi için önem arz etmektedir [11,12]. Arazi örtüsündeki bu değişimin tespitindeki en ucuz ve etkili yöntem, sinoptik görüş ve farklı zamanlarda veri sağlayabilmesi avantajları ile uzaktan algılamadır. Sentinel-1A uydusu Avrupa uzay ajansı tarafından 2014 yılında fırlatılmıştır. Hem tek hem de çift polarize C-band görüntüler sağlamaktadır. Görüntüler, işleme seviyelerine göre (Seviye 0 ve Seviye 1) ve görüntü alım tiplerine (stripmap, Interferometric wide swath-IW vd.) göre kullanıcılara sunulurlar [13,14]. Kullanılan SAR görüntünün özellikleri Tablo I'de görülmektedir.

TABLO I. SENTİNEL-1A GÖRÜNTÜ ÖZELLİKLERİ

ÖZELLİKLER	SENTİNEL-1A
Görüntü Tarihi	19 Ocak 2017
Yörünge	Alçalan
Görüntüleme Tipi	İnterferometrik WS
Zamansal Çözünürlük	12 gün
Dalga boyu	C-bant (5,4 GHz)
Polarizasyon	Çift (DD, DY)
İşlenme Seviyesi	Seviye 1 (Ground Range Detected)



Şekil. 1. Çalışma Alanı (Band Kombinasyonu: DD/DDY/DD-DY)

Şekil 1'de görünen çalışma alanında beş adet arazi örtüsü/kullanımı sınıfı tespit edilmiştir (Tablo II). Sınıflar CLC2012 (Corine Land Cover 2012) ve Google Earth yardımıyla belirlenmiş ve daha sonra eğitim/test verileri de Google Earth'deki yüksek çözünürlüklü uydu görüntüleri yardımıyla oluşturulmuştur.

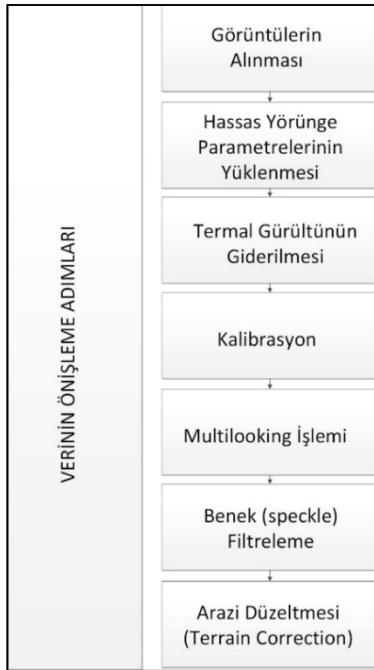
TABLO II. EĞİTİM VE TEST VERİSİ PİKSEL SAYILARI

Sınıf No	Sınıflar	Eğitim Verisi (Piksel)	Test Verisi (Piksel)
1	Su	1013	3299
2	Orman	1776	4588
3	Tarım	1266	2527
4	Çıplak Alanlar	1749	3007
5	Yerleşim	1256	2244

III. SAR VERİSİNİN ÖN İŞLENMESİ VE SINIFLANDIRMA

A. SAR Verisinin Ön işlenmesi

Ham olarak elde edilen uydu görüntülerine, sınıflandırma işlemi öncesinde bazı ön işleme adımlarının (geometrik ve atmosferik düzeltme vb.) uygulanması gerekmektedir. Bu ön işleme adımlarının sınıflandırma doğruluğuna etkisi vardır. Ham olarak elde edilen SAR görüntüleri de sınıflandırma öncesinde bazı işlemlerden geçirilir. Görüntü ön işleme adımları Avrupa Uzay Ajansı'nın ücretsiz olarak sağladığı SNAP yazılımı ile gerçekleştirilmiştir [15].



Şekil 2. Veri Ön İşleme Adımları

İlk işlem olarak SAFE formatında sunulan görüntünün DD ve DY polarizasyona sahip bantları görüntülenmiştir. Daha sonra yazılım aracılığı ile hassas yörünge parametreleri (RESORB) yüklenmiştir. Görünge parametreleri, görüntünün geometrik doğruluğu için ek parametreler sağlamaktadır. Bu işlemin ardından SNAP yazılımında Sentinel-1A görüntüsündeki termal gürültünün giderilmesi işlemi gerçekleştirilmiştir. Verinin kalibrasyonu işleminde ise Sigma Nought kalibrasyon seçilmiştir. Elde edilen bantlardaki piksel dijital değerleri, radar gerisayılım (db) değerine dönüştürülmüştür ve ardından multilooking işlemine

geçilmiştir. Benek filtreleme işleminde ise 5×5 pencere boyutunda Gamma Map filtresi kullanılmıştır. Arazi düzeltmesi işlem adımı ise 30 m çözünürlüklü SRTM (Shuttle Radar Topography Mission) sayısal yükseklik modeli kullanılmıştır. Bu işlemlerin ardından piksel boyutu 20 m yersel çözünürlüğe örneklenmiştir. SAFE formatında kayıtlı olan görüntü bu işlemlerin ardından GeoTIFF formatında kaydedilmiş ve çalışma alanını kaplayacak şekilde kesilmiştir. Görüntü, sınıflandırma işlemine hazır hale getirilmiştir.

B. Sınıflandırma

Uydu görüntülerinin sınıflandırılması, görüntüdeki piksellerin tanımlanan sınıflardan herhangi birine atanması olarak ele tanımlanabilir ve uzaktan algılamada görüntülerden bilgi çıkarımı amacıyla kullanılan en yaygın yöntemlerden birisidir [16,17]. Özellikle son yıllarda ileri düzey sınıflandırma algoritmaları (derin öğrenme, yarı güdümlü öğrenme, topluluk öğrenme algoritmaları vb.) uzaktan algılamada sıklıkla kullanılmakta ve yüksek doğrulukta sonuçlar vermektedir. Çalışmamız kapsamında makine öğrenme algoritmalarından DVM, RO ve K-EYK algoritmaları kullanılmıştır. En yaygın olarak kullanılan topluluk öğrenme algoritmaları (çoklu sınıflama algoritmaları) torbalama (bagging), hızlandırma (boosting) ve rastgele orman (random forest) algoritmalarıdır. Ağaç tabanlı bir sınıflandırma yöntemi olan rastgele orman algoritması sınıflandırma işleminde birden fazla karar ağacı kullanır [16,17]. Ağaçların torbalanması ve rastgele özellik seçimi işlemlerine göre sınıflandırma işlemini gerçekleştirmektedir. Bu yöntem, girdi veriyi (eğitim verisi ve görüntü) rastgele olarak alt kümelerle böler ve birden fazla sınıflandırma sonucu üretir. Sonuç sınıflandırma için oy çokluğuna dayalı sistem (majority voting) kullanır. Piksel en fazla ağaç sayısına sahip olduğu sınıfa (majority voting) atanır [18]. Rastgele orman algoritmasında N (ağaç sayısı) ve m (parametre sayısı) parametrelerinin kullanıcı tarafından girilmesi gerekmektedir. Bu değerler N=200 ve m=2 olarak belirlenmiştir. Çalışma kapsamında kullanılan diğer bir sınıflandırma yöntemi ise Destek Vektör Makineleri yöntemidir. Bu yöntem iki sınıfı birbirinden ayırabilen en uygun hiperdüzlemin belirlenmesi esasına dayalı kernel tabanlı bir sınıflandırma yöntemidir. Parametrik olmayan yapısı ve az eğitim verisi ile yüksek doğrulukta sonuçlar vermesi nedeniyle uzaktan algılamada sıklıkla tercih edilmektedir [19]. Çalışma kapsamında polinom kerneli ve radyal tabanlı fonksiyon kerneli kullanılmıştır. Polinom kerneli için polinom derecesi 3, ceza parametresi 100 olarak, radyal tabanlı fonksiyon kerneli için ise ceza parametresi 800 olarak alınmıştır. İki kernel yönteminde de gamma parametresi 0.1 olarak alınmıştır. Makine öğrenme algoritmalarından birisi olan K-En yakın komşuluk yönteminde ise piksel öznitelik uzayında kendisine en yakın uzaklıktaki k adet pikselin (k= komşu piksel sayısı=7) baskın/çok olduğu sınıfa atanır. Pikseller arası mesafenin belirlenmesinde Öklid mesafesi kullanılmıştır [20]

IV. DOĞRULUK ANALİZİ VE SONUÇLAR

A. Doğruluk Analizi

Çalışma kapsamında, orijinal bantlara (DD, DY) ek olarak matematiksel işlemler sonunda üç adet ek bant (DD-DY, DD+DY, DD-DY/DD+DY) oluşturulmuştur. Daha sonra bu bantların farklı dizilimlerinden oluşan dört farklı veri kümesi

oluşturulmuştur (Tablo III). Sınıflandırılmış görüntülerin doğruluk analizi ise, hata (confusion) matrislerden faydalanarak hesaplanan toplam doğruluk ve kappa katsayısına göre yapılmıştır. Çalışmada en yüksek sınıflandırma doğruluğu (%81.90) orijinal iki bandın DVM yöntemi ile sınıflandırılması sonucu elde edilmiştir (Tablo IV).

TABLO III. KULLANILAN VERİ KÜMELERİ

VERİ KÜMESİ	BANDLAR
1	DD, DY
2	DD, DY, (DD-DY)
3	DD, DY, (DD+DY)
4	DD, DY, (DD-DY)/(DD+DY)

Tüm veri kümeleri üç farklı sınıflandırma yöntemi ile sınıflandırılmış ve 1.veri kümesine olan etkisi incelenmiştir. Sınıflandırma sonuçları, toplam doğruluk ve kappa katsayılarına bakılarak değerlendirilmiştir (Tablo IV).

TABLO IV. SINIFLANDIRMA DOĞRULUKLARI (TÜM VERİ KÜMELERİ İÇİN)

Veri Kümesi	RO		K-EYK	
	TD (%)	Kappa	TD (%)	Kappa
1	79.22	0.7347	79.41	0.7366
2	79.30	0.7357	79.29	0.7351
3	79.62	0.7398	79.36	0.7360
4	79.49	0.7381	79.48	0.7375
	DVM (Pol)		DVM (RTF)	
	TD (%)	Kappa	TD (%)	Kappa
1	81.90	0.7684	81.00	0.7573
2	81.06	0.7581	80.56	0.7520
3	81.81	0.7674	80.83	0.7570
4	80.88	0.7559	81.21	0.7601

B. Sonuçlar

Bu çalışmada, Sentinel-1A SAR (Sentetik Açıklıklı Radar) görüntüsünün arazi örtüsü ve kullanımı sınıflandırmasında kullanılabilirliği ve sınıflandırma algoritmaları üzerindeki etkileri araştırılmıştır. Kullanılan üç farklı sınıflandırma yöntemi için de tüm veri kümelerinde %79'un üzerinde sınıflandırma doğruluğuna ulaşılmıştır. Sonuçlar incelendiğinde RO ve K-EYK yöntemleri %80 doğruluğa ulaşamaz iken DVM yöntemi tüm sınıflandırmalarda %80 doğruluğun üzerine çıkmıştır. Ek bantların sınıflandırma doğruluğuna olan etkileri incelenmek istendiğinde ise; DD-DY ile DD+DY bantları sınıflandırma algoritmalarına aynı etkilere sahiptir. RO dışında sınıflandırma doğruluğu azalmıştır. (DD-DY)/(DD+DY) ek bandında ise, DVM polinom fonksiyonu dışında artış olmuştur. Sonuçlar incelendiğinde, uygun spektral bant seçiminin sınıflandırma doğruluğu üzerindeki etkisi açıkça görülmektedir ve bilgi artışı her zaman sınıflandırma doğruluğunu artırmamaktadır. Çalışmada en yüksek sınıflandırma doğruluğu (%81.90) DVM yöntemi ile elde edilmiştir. Bu çalışma ile Sentinel-1A SAR verisinin sadece orijinal verileri ile istenilen doğrulukta arazi örtüsü kullanımı sınıflandırması yapılabileceği sonucuna varılmıştır.

KAYNAKLAR

- [1] Khatami, R., Mountrakis, G., and Stehman, S.V.: 'A meta-analysis of remote sensing research on supervised pixel-based land-cover image classification processes: General guidelines for practitioners and future research', *Remote Sensing of Environment*, 2016, 177, pp. 89-100
- [2] Hu, H., and Ban, Y.: 'Multitemporal RADARSAT-2 ultra-fine beam SAR data for urban land cover classification', *Canadian Journal of Remote Sensing*, 2012, 38, (1), pp. 1-11
- [3] Lee, J.-S., and Pottier, E.: 'Polarimetric Radar Imaging From Basics to Applications' 2009 CRC Press.
- [4] Waske, B., and Braun, M.: 'Classifier ensembles for land cover mapping using multitemporal SAR imagery', *ISPRS Journal of Photogrammetry and Remote Sensing*, 2009, 64, (5), pp. 450-457
- [5] Balzter, H., Cole, B., Thiel, C., and Schmullius, C.: 'Mapping CORINE Land Cover from Sentinel-1A SAR and SRTM Digital Elevation Model Data using Random Forests', *Remote Sensing*, 2015, 7, (11), pp. 14876
- [6] Samat, A., Gamba, P., Du, P., and Luo, J.: 'Active extreme learning machines for quad-polarimetric SAR imagery classification', *International Journal of Applied Earth Observation and Geoinformation*, 2015, 35, Part B, pp. 305-319
- [7] Hütt, C., Koppe, W., Miao, Y., and Bareth, G.: 'Best Accuracy Land Use/Land Cover (LULC) Classification to Derive Crop Types Using Multitemporal, Multisensor, and Multi-Polarization SAR Satellite Images', *Remote Sensing*, 2016, 8, (8), pp. 684
- [8] Lu, D., and Weng, Q.: 'A survey of image classification methods and techniques for improving classification performance', *International Journal of Remote Sensing*, 2007, 28, (5), pp. 823-870
- [9] Kavzoglu, T.: 'Increasing the accuracy of neural network classification using refined training data', *Environmental Modelling & Software*, 2009, 24, (7), pp. 850-858
- [10] Pal, M., and Foody, G.M.: 'Feature Selection for Classification of Hyperspectral Data by SVM', *IEEE Transactions on Geoscience and Remote Sensing*, 2010, 48, (5), pp. 2297-2307
- [11] Maktav, D., and Erbek, F.S.: 'Analysis of urban growth using multi-temporal satellite data in Istanbul, Turkey', *International Journal of Remote Sensing*, 2005, 26, (4), pp. 797-810
- [12] Calò, F., Abdikan, S., Görüm, T., Pepe, A., Kiliç, H., and Balık Şanlı, F.: 'The Space-Borne SBAS-DInSAR Technique as a Supporting Tool for Sustainable Urban Policies: The Case of Istanbul Megacity, Turkey', *Remote Sensing*, 2015, 7, (12), pp. 15842
- [13] Torres, R., Snoeij, P., Geudtner, D., Bibby, D., Davidson, M., Attema, E., Potin, P., Rommen, B., Floury, N., Brown, M., Traver, I.N., Deghaye, P., Duesmann, B., Rosich, B., Miranda, N., Bruno, C., L'Abbate, M., Croci, R., Pietropaolo, A., Huchler, M., and Rostan, F.: 'GMES Sentinel-1 mission', *Rem. Sens. of Environ.*, 2012, 120, pp. 9-24
- [14] Sentinel-1 Team. *Sentinel-1 User Handbook*; European Space Agency: Rome, Italy, 2013.
- [15] SNAP, ESA, <http://step.esa.int/main/toolboxes/snap/>
- [16] Mather, P.M. & Koch, M., 2011. 'Computer Processing of Remotely-Sensed Images: An Introduction', Fourth Edition. Chichester, UK: Wiley-Blackwell, 504 pp
- [17] Rodriguez-Galiano, V.F., Ghimire, B., Rogan, J., Chica-Olmo, M., and Rigol-Sanchez, J.P.: 'An assessment of the effectiveness of a random forest classifier for land-cover classification', *ISPRS Journal of Photogrammetry and Remote Sensing*, 2012, 67, pp. 93-104
- [18] Waske, B., Benediktsson, J., and Sveinsson, J.: 'Random Forest Classification of Remote Sensing Data': 'Signal and Image Processing for Remote Sensing, Second Edition' (CRC Press, 2012), pp. 365-374
- [19] Pal, M.: 'Advanced algorithms for land use and cover classification': 'Advances in Mapping from Remote Sensor Imagery' (CRC Press, 2012), pp. 69-90
- [20] Franco-Lopez, H., Ek, A.R., and Bauer, M.E.: 'Estimation and mapping of forest stand density, volume, and cover type using the k-nearest neighbors method', *Remote Sensing of Environment*, 2001, 77, (3), pp. 251-274